

لماذا يمكن نسخ بعض ملفات **PDF** العربية والبحث فيها، بينما لا يمكن ذلك في ملفات أخرى؟

شرح تقني لبنية النص العربي داخل PDF

تقنيًا، قابلية النسخ والبحث في PDF تعتمد على كيفية تمثيل النص داخل بنية الملف، لا على شكله المرئي فقط.

1. أوامر رسم النص داخل PDF

في PDF، النص غالبًا يُرسم عبر أوامر مثل Tj وTJ داخل Content Stream. هذه الأوامر لا تخزن بالضرورة أحرف Unicode مباشرة؛ فقد تخزن أكواد glyphs مرتبطة بخط مضمّن داخل الملف. وهنا تظهر كثير من مشكلات العربية.

2. أهمية ToUnicode CMap

أهم عنصر لاستخراج النص بصورة صحيحة هو جدول ToUnicode CMap. هذا الجدول يربط الكود المستخدم داخل PDF بالحرف Unicode الصحيح، مثل ربط قيمة داخلية معينة بالحرف «م» أي U+0645. إذا كان هذا الجدول موجودًا وصحيحًا، يستطيع قارئ PDF تحويل ما يراه إلى نص قابل للبحث والنسخ. وإذا كان مفقودًا أو خاطئًا، فقد تظهر العربية سليمة بصريًا بينما يعطي النسخ رموزًا غريبة أو نصًا غير مفهوم.

مثلًا، قد يحتوي الملف داخليًا على شيء قريب من:

```
<01> → glyph_73  
<02> → glyph_18  
<03> → glyph_95
```

العارض يعرف كيف يرسم هذه الـ glyphs، لذلك تبدو الصفحة صحيحة. لكن إذا لم توجد خريطة Unicode صريحة، فلا يعرف برنامج استخراج النص ما الحروف التي تمثلها تلك الأشكال.

```
<01> → U+0627  
<02> → U+0644  
<03> → U+0645
```

3. العربية: BiDi وArabic Shaping

العربية أصعب قليلًا لأن النص يمر عادة بمرحلتين قبل الرسم: BiDi لتحديد الاتجاه، وArabic shaping لتحويل الحروف إلى glyphs مناسبة حسب موقعها في الكلمة. لذلك قد تخزن بعض مولدات PDF الناتج البصري النهائي بدل النص المنطقي. عندها قد تكون كلمة مثل «سلام» مخزنة كـ glyphs موضوعة من اليمين إلى اليسار، وليس كسلسلة Unicode بسيطة من الحروف.

CIDFonts و Type 0.4

يستخدم PDF كثيرًا خطوط CIDFonts و Type 0. في هذه الحالة تكون الأكواد الداخلية CIDs وليست Unicode مباشرة. وجود ToUnicode يصبح حاسمًا لاستخراج النص. ولهذا قد تجد ملفين يستخدمان الخط العربي نفسه ويبدوان متطابقين، لكن أحدهما قابل للبحث والنسخ والآخر لا.

5. ملفات PDF الممسوحة ضوئيًا

هناك حالة مختلفة تمامًا: PDF الممسوح ضوئيًا. في هذا النوع قد يحتوي Content Stream على صورة فقط، مثل Image XObject، ولا يوجد نص أصلاً.

```
/Im1 Do
```

في هذه الحالة لا يوجد ما يمكن لمحرك البحث أو النسخ استخراجه، لأن الصفحة بالنسبة للبرنامج مجرد بكسلات. الحل هو OCR، أي التعرف البصري على الحروف.

6. Searchable PDF و طبقة OCR المخفية

بعد OCR، غالبًا يُنشأ ما يسمى Searchable PDF: تبقى الصورة الأصلية كما هي، وتضاف طبقة نص غير مرئية فوقها أو تحتها. تقنيًا يمكن رسم النص باستخدام Text Rendering Mode يجعل النص موجودًا في بنية PDF لكنه غير ظاهر.

```
3 Tr
```

لهذا تستطيع البحث والنسخ من ملف يبدو ظاهريًا كأنه صورة ممسوحة ضوئيًا. جودة النص المنسوخ تعتمد هنا على دقة OCR.

7. مشكلات أخرى في استخراج العربية

حتى مع وجود نص، قد يفشل الاستخراج أو يكون جزئيًا بسبب تقسيم كل حرف إلى عنصر مستقل، أو وضع الحروف بإحداثيات منفصلة بدل تخزينها كسلسلة، أو استخدام Private Use Area، أو عدم وجود مسافات فعلية بين الكلمات، أو تخزين الأحرف بترتيب بصري Visual Order بدل الترتيب المنطقي Logical Order.

عندها قد يحاول برنامج الاستخراج إعادة بناء ترتيب القراءة اعتمادًا على مواقع glyphs في الصفحة، وقد ينتج نصًا معكوسًا أو أحرفًا متباعدة.

م ا ل س

: بدلاً من

سلام

8. قيود النسخ والحماية

منع النسخ موضوع آخر منفصل عن الترميز. قد يحتوي PDF على Encryption Dictionary وصلاحيات ضمن Standard Security Handler تشير إلى منع استخراج النص أو نسخه. في هذه الحالة قد يكون النص موجودًا ومشفرًا بشكل صحيح، لكن القارئ يطبق قيود الصلاحيات.

9. كيف نشخص ملف PDF عربي؟

- هل الصفحة تحتوي على ET ... BT وعمليات Tj/TJ، أم على صور فقط؟
- ما نوع الخطوط: Type0، CIDFontType2، TrueType وغيرها؟
- هل لكل خط ToUnicode stream؟
- هل النص المستخرج Unicode عربي صحيح؟
- هل ترتيب glyphs منطقي أم بصري؟
- هل توجد طبقة OCR مخفية؟
- هل الملف مشفر وله قيود تمنع extraction؟

10. أدوات فحص مفيدة

أداة pdffonts مفيدة لمعرفة الخطوط المضمنة وبعض معلومات الترميز؛ ومن الأعمدة المهمة فيها عمود uni الذي يساعد على معرفة وجود Unicode mapping. أما pdftotext فيكشف عمليًا جودة طبقة النص ومدى قدرة الأدوات على استخراج العربية بصورة سليمة.

الخلاصة

وجود كلمات عربية ظاهرة على الشاشة لا يعني أن PDF يحتوي على نص عربي حقيقي. قد تكون الصفحة صورة، أو glyphs بلا ToUnicode، أو نص OCR مخفيًا، أو نصًا صحيحًا مع قيود نسخ. الفرق الحقيقي يُحسم بفحص بنية الصفحة، الخطوط، خرائط Unicode، وترتيب glyphs.